uniandes

SUMO · sumo-rl · PyTorch

DEPARTAMENTO DE INGENIERÍA ELÉCTRICA Y ELECTRÓNICA · TALLER DE CONTROL

Control semafórico multiagente con RND-MAPPO

Aprendizaje por refuerzo para cuatro intersecciones semaforizadas de Bogotá simuladas en SUMO

Grupo: Tomás Castro Roa · [Integrante] · [Integrante] · [Integrante]

Profesor: [Nombre del profesor] · 28 de octubre de 2026

ESTRUCTURA

Agenda de la presentación

Formulación, arquitectura, evaluación experimental y análisis

01 Formulación del problema

Escenario SUMO de cuatro intersecciones; observaciones, acciones y recompensa de cada agente.

02 Arquitectura RND-MAPPO

Actores descentralizados, crítico centralizado, exploración por RND e hiperparámetros.

03 Resultados

Curvas de aprendizaje, comparación con tiempo fijo, sensibilidad a la demanda y demostración.

04 Análisis y conclusiones

Política estocástica frente a greedy, variantes de entrenamiento y trabajo futuro.

EL PROBLEMA

Descripción del escenario

Red vial de un sector de Bogotá importada de OpenStreetMap y simulada en SUMO

4 intersecciones semaforizadas (C1 a C4)

3600 s por episodio, con decisiones cada Δt = 5 s (720 pasos)

≈1.380 viajes completados por hora con la demanda nominal

Parámetro	Valor
Simulador	SUMO 1.27 · sumo-rl 1.4.5
Demanda	Rutas aleatorias + flujos específicos
Verde mínimo	15 s (impuesto por sumo-rl)
Verde máximo	60 s configurado, no aplicado
Amarillo	3 s obligatorio
Teletransporte	Desactivado
Referencia	Programas de tiempo fijo de la red

FORMULACIÓN

Formulación del problema de control

Juego estocástico parcialmente observable con un agente por intersección

Elemento	Definición	Implementación
Agente i	Controlador de la intersección Ci, i = 1…4	Un actor por intersección
Observación oi	Fase activa (one-hot), indicador de verde mínimo, densidad y cola por carril de entrada	DefaultObservationFunction
Acción ai	Selección directa de la siguiente fase verde	Discreta; |Ai| = n.º de fases
Recompensa ri	Reducción de cola y de espera acumulada, con penalización por cambio de fase	Por intersección, cada Δt
Estado global s	Concatenación de las cuatro observaciones	Entrada del crítico
Horizonte	720 pasos de 5 s; factor de descuento γ = 0,99	1 episodio = 1 h simulada

ARQUITECTURA

MAPPO: entrenamiento centralizado, ejecución descentralizada

Actor $\pi_i(a_i \mid o_i)$

`oi → 128 → 64 → |Ai| · ReLU · softmax`

Distribución categórica sobre las fases. Cuatro actores independientes, porque $|o_i|$ y $|A_i|$ difieren entre intersecciones.

Crítico $V(s)$

`s → 256 → 128 → 1 · ReLU`

Valor del estado global (las cuatro observaciones). Compartido por los cuatro agentes y usado solo en el entrenamiento.

Objetivo PPO

Pérdida recortada con $\varepsilon = 0{,}2$ y bono de entropía $cH = 0{,}01$.

Ventaja GAE

$\gamma = 0{,}99$ y $\lambda = 0{,}95$, con ventajas normalizadas por lote.

Ejecución

Cada controlador decide solo con o_i: no requiere comunicación entre intersecciones.

RECOMPENSA

Recompensa extrínseca y exploración por RND

Random Network Distillation como bono intrínseco con peso decreciente

$$R_{ext} = -(w1 \cdot \Delta Q + w2 \cdot \Delta W_{veh} + w3 \cdot \Delta W_{ped}) - P \cdot 1[\text{cambio de fase}]$$

$$R_{int} = \| f\theta(s') - g(s') \|^2$$

$$R_{total} = R_{ext} + \lambda e \cdot R_{int}, \quad \lambda e = \max(0{,}01 \; ; \; 1 - e/E)$$

Término extrínseco

ΔQ y ΔW: variación de cola y de espera acumulada entre pasos. w1 = w2 = 1, P = 0,5; w3 = 2 sin efecto (no hay peatones).

Término intrínseco

g: red aleatoria fija; fθ: predictor entrenado para imitarla. El error es alto en estados poco visitados.

Decaimiento de λ

Lineal en el episodio e de E: exploración al inicio y optimización del tráfico al final.

ENTRENAMIENTO

Configuración experimental

Hiperparámetros del entrenamiento y protocolo de evaluación

Hiperparámetro	Valor
Episodios	100
Tasa de aprendizaje actor / crítico	$3{\cdot}10^{-4}$ / $1{\cdot}10^{-3}$
Recorte PPO ε / entropía cH	0,2 / 0,01
Épocas PPO por episodio	4
γ / λGAE	0,99 / 0,95
Tasa de aprendizaje RND	$1{\cdot}10^{-4}$
Corridas independientes	3 (base, semilla 1, semilla 2)

Semillas pareadas
5 semillas de SUMO (10 a 50); agente y tiempo fijo ven la misma demanda.

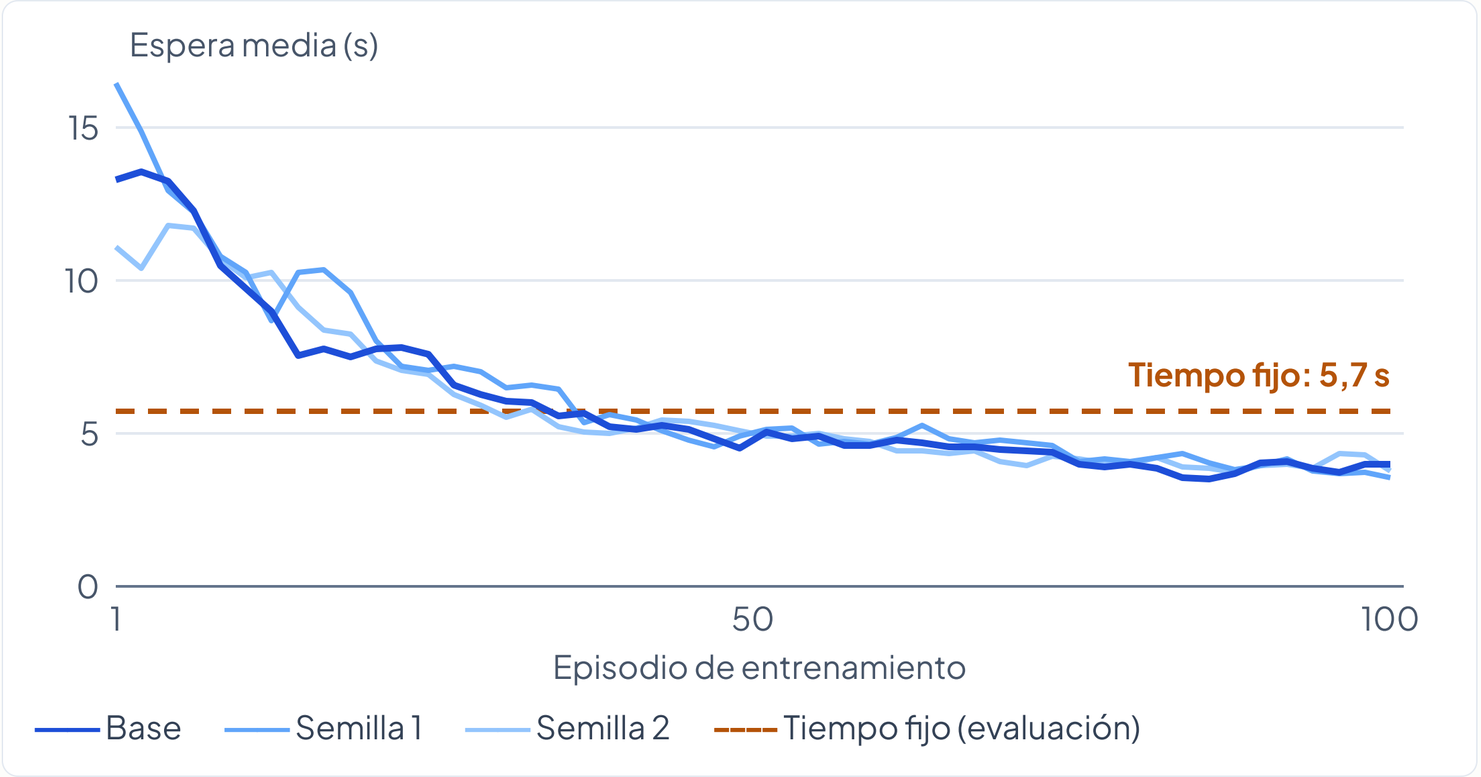
Tres niveles de demanda
80 %, 100 % y 120 % del tráfico nominal (opción --scale de SUMO).

26 métricas
Sistema, por viaje (tripinfo), emisiones y control; prueba t pareada.

RESULTADOS

Curvas de aprendizaje

Espera media por vehículo en cada episodio de entrenamiento (media móvil de 5 episodios)



12,0 → 3,8 s
espera media, primeros y últimos 10 episodios (corrida base)

≈ 35
episodio en que se alcanza el nivel del tiempo fijo

3,8–4,0 s
nivel final de las tres corridas independientes

RESULTADOS

Desempeño frente al control de tiempo fijo

Política base, demanda nominal, 5 semillas pareadas

Métrica	Tiempo fijo	RND-MAPPO	Variación	p
Espera media (s)	5,73	2,91	−49,3 %	< 0,001
Vehículos detenidos (promedio)	13,98	6,71	−52,0 %	< 0,001
Tiempo perdido por viaje (s)	53,8	34,8	−35,3 %	< 0,001
Tiempo de viaje (s)	134,9	115,9	−14,1 %	< 0,001
Espera por viaje, percentil 95 (s)	101,4	61,5	−39,4 %	< 0,001
Velocidad media (m/s)	6,23	7,32	+17,4 %	< 0,001
CO_2 emitido (kg/h)	346,9	303,8	−12,4 %	< 0,001
Viajes completados (veh/h)	1376	1387	+0,8 %	0,001
Cambios de fase (por hora)	916	489	−46,6 %	< 0,001

RESULTADOS

Sensibilidad al nivel de demanda

Política entrenada con la demanda nominal y evaluada con ±20 % de vehículos, sin reentrenar

Demanda	Espera fijo (s)	Espera RL (s)	Pérdida fijo (s)	Pérdida RL (s)	Detenidos máx. fijo	Detenidos máx. RL
80 %	5,73	2,79	49,1	30,1	25,4	14,8
100 % (nominal)	5,73	2,91	53,8	34,8	36,2	22,0
120 %	5,87	3,40	61,5	41,2	46,0	29,0

−42 a −51 %
variación de la espera media en los tres niveles

−33 a −39 %
variación del tiempo perdido por viaje

$p < 0{,}01$
en los tres niveles de demanda

RESULTADOS

Desempeño por intersección

Demanda nominal, promedio de 5 semillas

Intersección	Espera fijo (s)	Espera RL (s)	Cambios fijo	Cambios RL	Verde medio fijo (s)	Verde medio RL (s)
C1	4,2	2,6	239	141	12,5	25,4
C2	148,7	73,4	319	176	10,0	20,4
C3	140,7	47,4	239	172	14,2	20,8
C4	12,3	0,0	119	0,4	26,7	3120

C2 y C3 concentran la congestión

La espera acumulada baja 51 % y 66 %. El verde medio pasa de 10–14 s a unos 20 s, con menos cambios de fase.

C4 mantiene una sola fase

Verde medio de 3120 s con espera nula: la demanda transversal es casi inexistente, y sumo-rl no aplica el verde máximo.

DEMOSTRACIÓN

Ejecución en tiempo real en sumo-gui

Misma demanda y semilla: tiempo fijo (izquierda) frente a RND-MAPPO (derecha)

COMANDO

```
python demo_en_vivo.py --minutos 10 --delay 300 --escala 1.2
```

−48 % · −57 %

vehículos detenidos y espera media en la prueba de referencia (15 min, demanda nominal, semilla 10)

1 · Escenario
Semilla 10, demanda ×1,2, 10 min simulados

2 · Dos instancias de sumo-gui
Procesos paralelos con la misma ruta y semilla

3 · Marcador en terminal
Detenidos, espera media y vehículos llegados

4 · Resumen
Variación porcentual promedio al final

ANÁLISIS

Política estocástica frente a política greedy

Muestreo de π(a | o) frente a argmax de π, demanda nominal, 5 semillas

Métrica	Tiempo fijo	Estocástica	Greedy
Espera media (s)	5,7	2,9	165,3
Tiempo de viaje (s)	134,9	115,9	109,6
Tiempo perdido (s)	53,8	34,8	28,2
Viajes completados	1376	1387	1369
Viajes sin terminar	52,8	41,6	58,6
Cambios de fase	916	489	358

Sesgo de supervivencia

Las métricas por viaje solo incluyen los vehículos que llegan. La política greedy concentra el verde en pocas fases: los vehículos retenidos no terminan el viaje y la espera media del sistema crece 29 veces.

ANÁLISIS

Variantes de entrenamiento

Evaluación con demanda nominal y 5 semillas; variación frente al tiempo fijo

Variante	Cambio respecto a base	Episodios	Espera (s)	Δ espera	p	Δ viaje
Base	—	100	2,91	−49 %	< 0,001	−14 %
Semilla 1	Semilla de entrenamiento	100	4,52	−21 %	0,22	−13 %
Semilla 2	Semilla de entrenamiento	100	4,24	−26 %	0,09	−12 %
Penaliza cambio	P = 2,0 solicitado (ver nota)	50	4,52	−21 %	< 0,001	−10 %
LR conservador	lr actor $1 \cdot 10^{-4}$, crítico $3 \cdot 10^{-4}$	50	8,14	+42 %	< 0,001	+4 %

Variabilidad entre corridas

Las semillas 1 y 2 reducen el tiempo de viaje con significancia, pero su espera media varía con la semilla de evaluación.

Nota sobre P = 2,0

El parámetro no llegó a la función de recompensa del entorno: esa corrida usó P = 0,5. Debe repetirse.

CIERRE

Conclusiones

01 Aprendizaje

Con CTDE, cuatro controladores aprenden una política de fase en unos 60 episodios; tres corridas convergen a 3,8–4,0 s.

02 Desempeño

Frente al tiempo fijo: espera −49 %, tiempo perdido −35 % y CO_2 −12 %, con la mitad de cambios de fase ($p < 0,01$).

03 Robustez

La mejora se mantiene con ±20 % de demanda sin reentrenar: −42 % a −51 % en espera media.

04 Evaluación

Las métricas por viaje ocultan vehículos retenidos; hay que combinarlas con métricas de sistema y de viajes no completados.

Trabajo futuro: aplicar el verde máximo y repetir la variante P = 2,0; simular la hora pico (flujos desde 5000 s); estabilizar el entrenamiento entre semillas; incluir peatones.

uniandes

CONTROL SEMAFÓRICO MULTIAGENTE CON RND-MAPPO

Gracias. ¿Preguntas?

Tomás Castro Roa · [Integrante] · [Integrante] · [Integrante]

github.com/santisan1205/Taller-Control